MPUM Miniprojekt 2

Jakub Stepaniuk

16 kwietnia 2026

Wprowadzenie

Projekt zawiera implementacje w sobie implementacje wybranych algorytmów klasyfikacji.

1. `logistic` - implementacja regresji logistycznej z regularyzacją
2. `logistic_testing` - testowanie implementacji regresji logistycznej dla różnych rozmiarów zbiorów treningowych
3. `bayesian` - implementacja naiwnego klasyfikatora bayesowskiego z wygładzeniem Lagrange'a
4. `bayesian_testing` - testowanie implementacji naiwnego klasyfikatora bayesowskiego dla różnych rozmiarów zbiorów treningowych
5. `bayesian_dependent` - naiwny klasyfikator bayesowski z dodatkowymi cechami zależnymi warunkowo od poprzednich
6. `bayesian_dependent_testing` - testowanie implementacji naiwnego klasyfikatora bayesowskiego z zależnymi warunkowo cechami dla różnych rozmiarów zbiorów treningowych

Dla każdego z podanych modeli kryterium jakości była jego dokładność. Nie stosowałem skalowania z wyjątkiem przemianowania zmiennej wynikowej z $(2, 4)$ na $(0, 1)$. Dane wejściowe w każdym modelu oryginalnie były dzielone na zbiory treningowy i testowy w proporcji bliskiej $2 : 1$.

Regresja logistyczna

Regresja logistyczna natychmiast, po dodaniu dodatkowego parametru na odchylenia o stałą osiągnęła dość wysoki odsetek poprawnych predykcji - ponad 95% lub wyżej.

Aby nieco poprawić wyniki zastosowałem regularyzację ℓ_1 z niewielkim parametrem 0.03. Na tych danych okazało się, że jedynie piąty był mniej istotny, niż pozostałe - każdy poza nim posiadał wagę w przedziale $[0.1, 0.3]$.

Duża część implementacji pozostała taka sama, co na poprzednim miniprojekcie - zmienił się oczywiście sam gradient, ale algorytm pozostał niemal taki sam.

Naiwny klasyfikator bayesowski

Prawdopodobieństwa warunkowe wybranych argumentów ujawniają kolejne zależności między parametrami wejściowymi a prawdziwą klasyfikacją. Dla przykładu - zerowa wartość parametru dziewiątego jest raczej często powiązane z nowotworami łagodnymi, albo wysokie wartości dowolnego parametru oznacza raczej nowotwór złośliwy. Podobne zależności można wydedukować spoglądając na dane w `bayes.data`.

W implementacji zastosowałem wygładzenie Lagrange'a. Odsetek poprawnych przewidywań w tym przypadku wynosił w przypadku tego modelu nawet więcej niż przy regresji logistycznej - było to nawet ponad 97%.

Oczywiście klasyfikator ten miał szansę zadziałać tak dobrze tylko dzięki niezależności warunkowej danych wejściowych pod warunkiem danej wyjściowej - inaczej wyniki mogłyby być znacznie gorsze.

Zależność błędu modelu od wielkości zbioru treningowego

Sprawdziłem wysokości błędów dla różnych przebiegów obu zaimplementowanych algorytmów dla rozmiarów zbioru testowego od 1% do 100% oryginalnego.

Błędy na poniższym wykresie są w skali logarytmicznej, by uwydatnić różnicę w błędach osiąganych przez oba modele.

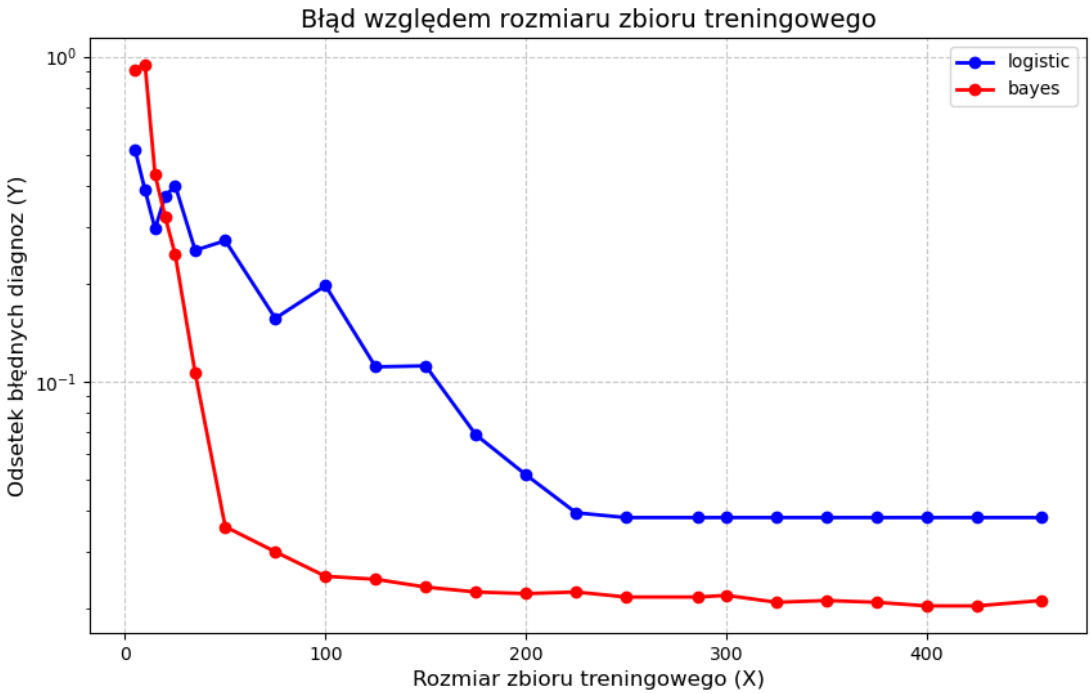

Rysunek 1: Zależność parametrów wejścia od parametru wynikowego

Można zaobserwować, że naiwny klasyfikator bayesowski staje się stabilny już dla mniejszych rozmiarów danych treningowych oraz ostatecznie osiąga istotnie lepsze wyniki. Te cechy, a nawet przybliżony kształt wykresów przypomina te znalezione w artykule. Trudno określić na podstawie jednego wyizolowanego przypadku zgodność z pozostałymi znaleziskami z artykułu, lecz przynajmniej część obserwacji wydaje się być podobna.

Artykuł „On Discriminative vs. Generative classifiers: A comparison of logistic regression and naive Bayes" Ng i Jordana zaznacza, że regresja logistyczna jest zdolna osiągać asymptotycznie niższe wartości błędów. Tutaj to jednak klasyfikator generatywny osiągnął lepsze wyniki, nawet po ustabilizowaniu się wyników klasyfikatora generatywnego. Pokazuje to, że asymptotycznie lepsze wyniki niekoniecznie oznaczają lepsze wyniki w każdym przypadku.

Propozycja o szybszej zbieżności klasyfikatora bayesowskiego wydaje się być prawdziwa w bardziej oczywisty sposób - już dla niewielkiego odsetka rozmiaru końcowego zbioru treningowego wielkość błędu spadła blisko tej osiąganej dla całego zbioru.

Powyższe dane zostały otrzymane dla kilkunastu przebiegów treningowych z różnymi podziałami na zbiór treningowy i testowy. Testowane rozmiary zbioru treningowego zostały zaznaczone

pogrubionymi kropkami na wykresie.

O niezależności cech

Dla sprawdzenia efektów niezależności cech na naiwny klasyfikator bayesowski wybrałem jedną z cech i umieściłem jej trzy dodatkowe duplikaty. W tym nowym modelu są więc cztery kopie tej samej cechy.

Na poniższym wykresie umieściłem ten dodatkowy model w porównaniu z pozostałymi:

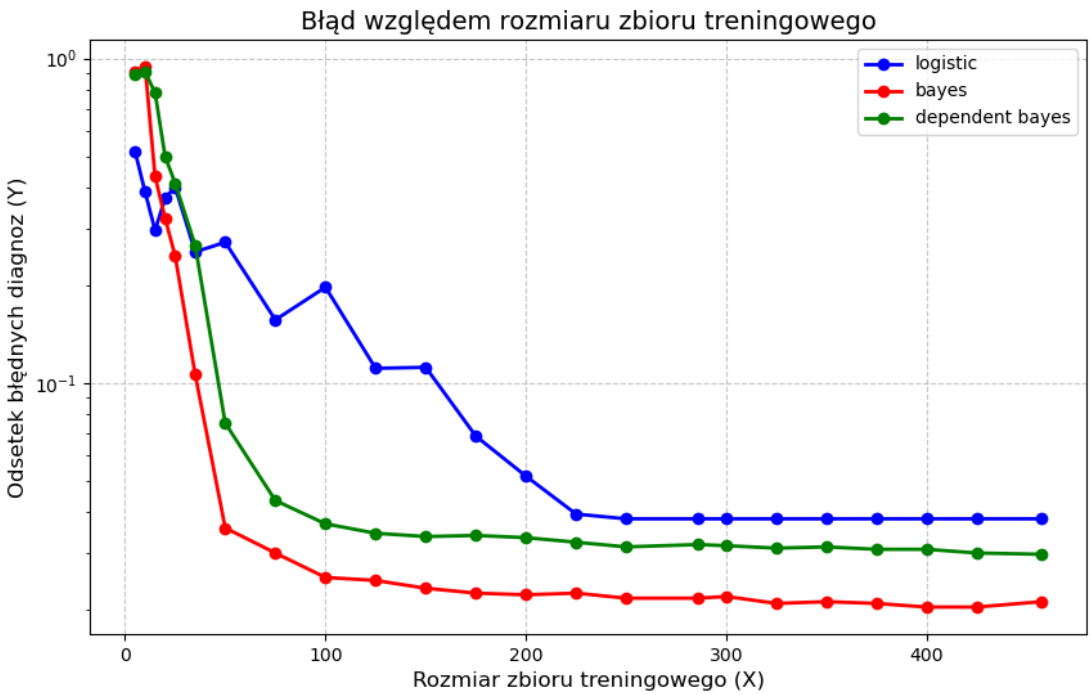

Rysunek 2: Zależność parametrów wejścia od parametru wynikowego

Te dodatkowe trzy cechy nie dodały żadnych dodatkowych informacji, ale ich występowanie w modelu znacznie zwiększyło istotność skopiowanej cechy w klasyfikacji - a to pogorszyło istotnie jakość samego klasyfikatora.